

Ukeoppgaver i uke 4, INF2440 – v2014

Denne uka skal vi også se på det å multiplisere to $n \times n$ matriser A og B sammen og regne ut resultatmatrisen C, altså $C = A \times B$, først sekvensielt (koden for en rett fram implementasjon av den sekvensielle versjonen finner du nederst i tips) og så parallelliser dette. Denne gangen skal vi dele opp data på en annen måte for trådene enn i Uke3. Anta at du har n rader og n kolonner i matrisen din og k tråder på din maskin. I uke3 skulle hver tråd beregne n/k **kolonner** i C, nå i uke4 skal vi se hva som skjer når trådene skal beregne n/k **rader** i C (husk at den siste tråden må regne ut alle de siste radene hvis n ikke er delbar med k).

Resultatet av $A \times B$ er selv en $n \times n$ matrise C, og vi har at element $c[i][j]$ i matrisen C er da definert som:

$$c[i][j] = \sum_{k=0}^n a[i][k] * b[k][j]$$


Vi multipliserer altså hvert element i rad i fra A parvis med hvert element fra kolonne j fra B og summerer de n multiplikasjonene for å få $c[i][j]$ (se koden).

Sekvensiell implementasjon – som i Uke3 – du kan bruke samme kode.

- a) Du skal før initiere matrisene A og b med tilfeldige double-tall fra klassen Random med metoden nextDouble(). Du får da et tilfeldig tall mellom 0,0 og 1,0. (Hvis du først vil teste koden din, kan du initiere A og B med 1,0, og da vil alle elementene i C være n .)

Test kjøretiden for $n=100$, 500 og 1000 og lag en liten tabell om kjøretiden som funksjon av n . Forklar hvorfor kjøretiden 8-dobles når n dobles.

Her du ser på hvordan to-dimensjonale arrayer er lagret i Java:



Da ser du at når vi beregner $c[i][j]$, så leser vi fra A tall fra en rad som ligger etter hverandre i lageret (raskt), mens elementene fra B hentes fra hver sin rad, og vi hopper rundt i lageret mellom alle radene. Det er forventet at du vil få problemer med cache-ene, og meget langsommere lesing av B-elementene. Du skal altså prøve ut en idé at du før du multipliserer sammen A og B, så bytter du om

på elementene i B, slik at kolonnene i B ligger lagret radvis som rader (på matematisk kalles dette å transponere B). Dette oppnår du hvis du bytter alle elementer $B[i][j]$ med $B[j][i]$ for alle $i < n$ og $j < i$ (grunnen til dette siste $j < i$ er å unngå å bytte om hvert element to ganger og dermed ende opp med at B ikke er endret). Du skal altså nå forsøke å multiplisere $A \times B$ med først å transponere B. Kall den B' , og da er :

$$c[i][j] = \sum_{k=0}^n a[i][k] * b'[j][k]$$

Ta også tider her (hvor tidene nå inkluderer først transponering av B og så multiplisering $A \times B'$ og se hvor mye får raskere tider enn rett fram multiplisering som definert i pkt a).

Parallell implementasjon – nå radvis

Dette er ett av de problemene hvor parallellisering er meget lett, en av de pinlig parallelle problemene. La bare tråd 0 beregne de n/k første **radene** i C, tråd 1 de neste n/k radene, ..., og den siste tråden alle de siste radene i C.

Siden dette ikke består i å skrive samtidig på felles variable, bare lese A og B (eller B'), trenger vi ikke noen synkronisering, bare en skikkelig avslutning av trådene – for eksempel med `join()`.

Inkluder din parallelle løsning med den beste av løsningene ovenfor og parallelliser denne. Siden løsningen med transponering var raskest, er det tilsvarende enkelt å parallellisere transponeringen av B. Begrunn hvorfor en transponering tar mye kortere tid enn selve multipliseringen. Det holder derfor bare i begge tilfellene ikke multipliserer transponeringen. Skriv en liten tabell over kjøretidene og speedup for din parallelle løsning og kommenter den. **Kommenter også ved å sammenligne resultatene fra Uke3 med disse resultatene:** Hva var best: Dele opp C radvis (uke4) eller kolonnevis(uke3)? Forklar forskjellene du fant.

Tips

Koden for sekvensiell beregning av $C = A \times B$:

```
double elem ;

for (int i=0;i < n;i++) {
    // for hver rad i C
    for (int j=0;j < n;j++) {
        // for hver kolonne i C
        elem =0.0;
        for (int k=0;k < n;k++){
            elem += a[i][k]*b[k][j];
        }
        c[i][j] = elem;
    } // end j
} // end i
```

Ukeoppgaver uke 3 INF2440 – v2014

Denne uka skal vi se på det å multiplisere to $n \times n$ matriser A og B sammen og regne ut resultatmatrisen C, altså $C = A \times B$, først sekvensielt (koden for en rett fram implementasjon av den sekvensielle versjonen finner du nederst i tips) og så parallelliser dette. Dette kan se ut som en veldig matematisk oppgave, og matriser brukes mye i løsning av store ingeniør-beregninger, men for å løse denne oppgaven trenger men ikke vite hva matriser brukes til. Det holder å vite at en matrise er simpelthen en todimensjonal double-array (eks. `double [][] a = new double[n][n]`; hvor n er et passende heltall – i vårt tilfelle mindre enn 1000).

Resultatet av $A \times B$ er selv en $n \times n$ matrise C, og vi har at element $c[i][j]$ i matrisen C er da definert som:

$$c[i][j] = \sum_{k=0}^n a[i][k] * b[k][j]$$


Vi multipliserer altså hvert element i rad i fra A parvis med hvert element fra kolonne j fra B og summerer de n multiplikasjonene for å få $c[i][j]$ (se koden).

Sekvensiell implementasjon

- a) Du skal før initiere matrisene A og b med tilfeldige double-tall fra klassen Random med metoden `nextDouble()`. Du får da et tilfeldig tall mellom 0,0 og 1,0. (Hvis du først vil teste koden din, kan du initiere A og B med 1,0, og da vil alle elementene i C være n.)

Test kjøretiden for $n=100$, 500 og 1000 og lag en liten tabell om kjøretiden som funksjon av n. Forklar hvorfor kjøretiden 8-dobles når n dobles.

Her du ser på hvordan to-dimensjonale arrayer er lagret i Java:



Da ser du at når vi beregner $c[i][j]$, så leser vi fra A tall fra en rad som ligger etter hverandre i lageret (raskt), mens elementene fra B hentes fra hver sin rad, og vi hopper rundt i lageret. Det er forventet at du vil få problemer med cache-ene, og da langsommere lesing av B-elementene. Du skal altså prøve ut en ide at før du multipliserer sammen A og B, så bytter du om på elementene i B, slik at

kolonnene i B ligger lagret radvis som rader (på matematisk kalles dette å transponere B). Dette oppnår du hvis du bytter alle elementer $B[i][j]$ med $B[j][i]$ for alle $i < n$ og $j < i$ (grunnen til dette siste $j < i$ er å unngå å bytte om hvert element to ganger og dermed ende opp med at B ikke er endret) Du skal altså nå forsøke å multiplisere AxB med først å transponere B. Kall den B' , og da er :

$$c[i][j] = \sum_{k=0}^n a[i][k] * b'[j][k]$$

Ta også tider her (hvor tidene nå inkluderer først transponering av B og så multiplisering AxB' og se om du får raskere tider enn rett fram multiplisering som definert i pkt a).

Parallell implementasjon

Dette er ett av de problemene hvor parallellisering er meget lett, en av de pinbart parallelle problemene. La bare tråd 0 beregne de n/k første kolonnene i C, tråd 1 de neste n/k trådene,,..., og den siste tråden alle de siste kolonnene i C.

Siden dette ikke består i å skrive samtidig på felles variable, bare lese A og B (eller B') , trenger vi ikke noen synkronisering, bare en skikkelig avslutning av trådene – for eksempel med `join()`.

Inkluder din parallelle løsning med den beste av løsningene a) eller b) ovenfor og parallelliser denne. Hvis løsning b) med transponering var raskest, er det tilsvarende enkelt å parallellisere transponeringen av B. Skriv en liten tabell over kjøretidene og speedup for din parallelle løsning og kommenter den.

Tips

Koden for beregning av $C = AxB$:

```
double elem ;

for (int i=0; i < n; i++) {
    // for each row i C
    for (int j=0; j < n; j++) {
        // for each collumn in C
        elem =0.0;
        for (int k=0; k < n; k++){
            elem += a[i][k]*b[k][j];
        }
        c[i][j] = elem;
    } // end j
} // end i
```